

Semana 8 Lectura sobre Reconocimiento de actividad

El artículo destaca cómo HAR se ha consolidado como un área de investigación en la última década, provocado por la cantidad de dispositivos portátiles como teléfonos y relojes inteligentes. Además, el avance de algoritmos de aprendizaje profundo y otras técnicas de aprendizaje automático aumentado las aplicaciones de HAR a diversos campos, incluyendo deportes, salud y bienestar, resaltando su potencial como herramienta para el monitoreo de la función cognitiva y física de adultos mayores.

El artículo menciona la creciente relevancia de HAR frente al aumento de la población de edad avanzada a nivel mundial, estimando un incremento para 2050, lo que conlleva importantes consecuencias sociales y de atención médica. HAR es una herramienta para el monitoreo de la salud física, funcional y cognitiva en el hogar. Sin embargo, el desarrollo de algoritmos de HAR enfrenta desafíos debido a la complejidad y variedad de las actividades diarias, la variabilidad entre sujetos, la tensión entre rendimiento y privacidad, la eficiencia computacional en dispositivos portátiles y la dificultad en la anotación de datos. La obtención de datos para estos algoritmos se realiza principalmente a través de sensores ambientales y sensores en dispositivos personales.

En cuanto a la implementación algorítmica, el artículo señala un aumento en el uso de métodos de Aprendizaje Profundo (DL) en la investigación de HAR, lo que ha mejorado la precisión en el reconocimiento. Sin embargo, los modelos de Aprendizaje Automático Clásico (CML) pueden ser más apropiados en ciertas aplicaciones de HAR debido al tamaño reducido de los conjuntos de datos y la disponibilidad de conocimiento experto para la formulación del problema.

El artículo describe el flujo de trabajo estándar para el diseño de metodologías basadas en HAR, que incluye la identificación del sensor y dispositivo, la recolección de datos y su anotación, la selección y entrenamiento del modelo de aprendizaje automático y, finalmente, la evaluación del modelo. En este sentido, el artículo se enfoca en los sensores acelerómetros, destacando sus buenos resultados en aplicaciones de HAR y su uso creciente en combinación con otros sensores debido a su capacidad para medir el movimiento del cuerpo humano, su asequibilidad y su fácil integración en dispositivos portátiles.

El análisis del artículo revela que la investigación en HAR se apoya en diversas fuentes de datos, incluyendo sensores inerciales (acelerómetros, giroscopios, magnetómetros), fisiológicos (ECG, EMG, ritmo cardíaco) y ambientales (temperatura, humedad, luz). En cuanto a los dispositivos utilizados como fuentes de datos, el artículo categoriza las

metodologías de HAR basadas principalmente en dispositivos independientes, teléfonos y relojes inteligentes.

El artículo también aborda las etapas de preprocesamiento y extracción de características de los datos de los sensores. Señala que el preprocesamiento es crucial para eliminar el ruido y preparar los datos para los modelos de reconocimiento, utilizando técnicas como filtros digitales y estadísticos, normalización y segmentación. La extracción de características se realiza principalmente en los dominios temporal y de frecuencia, siendo las características del dominio temporal las más utilizadas por su menor costo computacional. Sin embargo, en las metodologías basadas en DL, a menudo se omite esta etapa, ya que las redes neuronales profundas realizan la extracción de características de forma automática.

En cuanto a los modelos de clasificación, el artículo presenta una comparativa entre los modelos de CML y DL utilizados en HAR. A pesar del auge del aprendizaje profundo, los modelos de CML, como las Máquinas de Vectores de Soporte (SVM), los k-Vecinos Más Cercanos (kNN), los Árboles de Decisión (DT) y los Bosques Aleatorios (RF), siguen siendo utilizados y alcanzan buenos resultados con menores requisitos de datos y computacionales. Por otro lado, los modelos de DL, como las Redes Neuronales Convolucionales (CNN) y las Redes Neuronales Recurrentes (RNN), demuestran una gran capacidad para reconocer actividades más complejas y lograr alta precisión, aunque requieren más datos y tiempo de entrenamiento.

También analiza la disponibilidad de conjuntos de datos para la investigación en HAR, señalando que muchos de los conjuntos de datos utilizados no son de acceso público, lo que dificulta la reproducibilidad de los resultados y la comparación entre diferentes metodologías. Además, la mayoría de los modelos de HAR se prueban en un número limitado de conjuntos de datos y actividades, a menudo capturadas en entornos controlados, lo que plantea desafíos en términos de generalización y variabilidad entre sujetos.

El artículo concluye resaltando el progreso alcanzado por los sistemas HAR en la última década, especialmente aquellos basados en sensores, que ofrecen ventajas sobre las metodologías basadas en visión en términos de privacidad y requisitos computacionales. No obstante, el artículo también identifica limitaciones y propone futuras líneas de investigación, incluyendo el desarrollo de metodologías más generalizables a conjuntos de actividades heterogéneos y diversos usuarios, la exploración del aprendizaje por transferencia y la fusión de sensores, la investigación en reconocimiento de actividades a un nivel más granular basado en interacciones con objetos cotidianos y la priorización de la computación en el dispositivo con atención a los recursos de hardware y el impacto del posicionamiento y la orientación de los sensores.

Demrozi, F., Pravadelli, G., Bihorac, A., & Rashidi, P. (2020). Human activity recognition using inertial, physiological and environmental sensors: A comprehensive survey. *IEEE Access*, 8, 210816-210836.

10/03/2025